

Similaridad de los espacios de características generados por una red neuronal en Continual Learning

Eduards Alexis Mendez Chipatecua¹ and Juan Carlos Galvis Arrieta¹

Universidad Nacional de Colombia, Bogotá
emendezc@unal.edu.co and jcgaltvisa@unal.edu.co

Abstract. El aprendizaje continuo plantea el reto de incorporar información nueva sin sacrificar el conocimiento adquirido, fenómeno conocido como olvido catastrófico. En este trabajo exploramos cómo evolucionan los espacios de características internos de una red neuronal profunda a lo largo de varias etapas de entrenamiento y bajo diferentes estrategias de mitigación del olvido. Para ello, empleamos una arquitectura ResNet-18 entrenada secuencialmente sobre CIFAR-10, comparando dos enfoques: fine-tuning puro y replay con buffer de ejemplos. Medimos la similaridad de subespacios de activaciones mediante ángulos principales tras aplicar PCA en cada capa. Nuestros resultados revelan que las capas más próximas a la entrada mantienen subespacios casi invariantes, mientras que las capas profundas sufren cambios sustanciales tras cada nueva tarea.

Introducción

El aprendizaje continuo (continual learning, CL) es un paradigma de aprendizaje automático en el que un modelo observa datos de forma secuencial y debe incorporar nueva información sin olvidar el conocimiento previamente adquirido. A diferencia del entrenamiento *offline*, donde todos los datos están disponibles de antemano, en CL el modelo recibe una serie de tareas o flujos de datos sucesivos, obligándolo a adaptarse de manera incremental. Este escenario refleja mejor las condiciones del mundo real, donde los datos llegan de forma progresiva y los sistemas deben aprender y actualizarse sobre la marcha.

En visión por computador, las redes neuronales profundas han logrado logros sobresalientes en clasificación, detección y segmentación, pero habitualmente se entrenan en un único ciclo de datos estáticos. Cuando se aplican de manera secuencial, sufren el fenómeno conocido como *olvido catastrófico*: la adaptación a nuevos ejemplos degrada drásticamente el desempeño en las tareas anteriores. Superar este compromiso entre **plasticidad** (capacidad de aprender nuevas tareas) y **estabilidad** (preservar el conocimiento previo) constituye el principal desafío de CL.

La literatura propone tres grandes familias de estrategias para mitigar el olvido catastrófico:

1. **Regularización sobre pesos importantes**, como Elastic Weight Consolidation (EWC) o Synaptic Intelligence (SI), que penalizan los cambios en parámetros clave para tareas anteriores.
2. **Replay de datos**, ya sea mediante buffers de ejemplos reales o generativos, que reintroducen información pasada durante el entrenamiento de nuevas tareas.
3. **Expansión de la arquitectura**, agregando neuronas, módulos o mecanismos de *prompting* dedicados a cada tarea para aumentar la capacidad del modelo.

Gracias a estos métodos, se han logrado avances significativos en conjuntos de datos secuenciales de clasificación de imágenes. Sin embargo, siguen abiertas preguntas fundamentales sobre *cómo* y *dónde* se almacena el conocimiento a nivel de representaciones internas. En este trabajo nos enfocamos en analizar la evolución de los subespacios de activaciones de una ResNet-18 entrenada secuencialmente sobre CIFAR-10, comparando estrategias de fine-tuning y replay. Para ello, aplicamos análisis de componentes principales (PCA) y mediciones de ángulos principales en cada capa, con el fin de entender mejor el compromiso estabilidad-plasticidad en redes de visión.

Configuración experimental

Escenario de tareas Trabajamos sobre CIFAR-10 dividiendo sus 10 clases en **2 tareas secuenciales** de 5 clases cada una. En cada paso $t \in \{0, 1\}$, el modelo ve únicamente las imágenes de las dos clases correspondientes a la tarea t . Cada experimento se repitió varias veces con distintas permutaciones aleatorias del orden de las clases; los resultados fueron consistentes independientemente de la permutación.

Estrategias de entrenamiento Comparamos dos enfoques de aprendizaje continuo sobre este único escenario:

- **Fine-tuning:** entrenamiento estrictamente secuencial, sin mecanismos de mitigación de olvido.
- **Replay:** durante el entrenamiento en la tarea t , el lote se construye mezclando ejemplos de las dos clases nuevas con un buffer fijo de *8 000 muestras totales* de las tareas previas, extraídas de forma aleatoria.

Detalles de entrenamiento

- *Arquitectura:* ResNet-18 sin-preentrenar.
- *Optimizador:* SGD con tasa de aprendizaje inicial 0.01, momento 0.9 y decaimiento de peso 5×10^{-4} .
- *Épocas por tarea:* 30.
- *Batch size:* 128.
- *Preprocesamiento:* imágenes redimensionadas a 224×224

Repositorio completo El repositorio con todas las configuraciones experimentales y los resultados de los experimentos está disponible en: <https://github.com/eguar11011/Continual>

Métricas de evaluación Al concluir la última tarea, reportamos:

- *Exactitud global final*: accuracy obtenida en las 10 clases.
- *Exactitud por tarea*: accuracy individual de cada tarea al finalizar su entrenamiento.
- *Análisis de subespacios*: aplicamos PCA a las activaciones de cada capa y medimos los ángulos principales entre subespacios de tareas sucesivas para cuantificar los cambios en las representaciones.

Métrica de similaridad entre representaciones

Dado un mismo conjunto de ejemplos, consideramos dos matrices de activaciones $\mathbf{X}, \mathbf{Y} \in \mathbb{R}^{N \times d}$ obtenidas en distintos momentos del entrenamiento (o de dos modelos diferentes). Cada fila corresponde a un ejemplo y cada columna a la activación de una neurona. Para cuantificar cuánto varían las *representaciones internas* empleamos la métrica de *ángulos principales* entre los subespacios generados por las K componentes principales de cada matriz.

1. **Centrado.** Restamos la media por dimensión: $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}\mu_X^\top$ y $\tilde{\mathbf{Y}} = \mathbf{Y} - \mathbf{1}\mu_Y^\top$, con $\mu_X, \mu_Y \in \mathbb{R}^d$.
2. **PCA.** Aplicamos SVD a cada matriz centrada y retenemos las K direcciones de máxima varianza:

$$\tilde{\mathbf{X}} = \mathbf{U}_X \boldsymbol{\Sigma}_X \mathbf{V}_X^\top, \quad \tilde{\mathbf{Y}} = \mathbf{U}_Y \boldsymbol{\Sigma}_Y \mathbf{V}_Y^\top,$$

$\mathbf{U}_1 := \mathbf{V}_X(:, 1:K)$ y $\mathbf{U}_2 := \mathbf{V}_Y(:, 1:K)$ forman bases ortonormales de sus respectivos subespacios.

3. **Ángulos principales.** Calculamos la proyección cruzada $\mathbf{C} = \mathbf{U}_1^\top \mathbf{U}_2 \in \mathbb{R}^{K \times K}$ y su SVD $\mathbf{C} = \mathbf{P} \boldsymbol{\Sigma} \mathbf{Q}^\top$. Los valores singulares σ_i satisfacen $\sigma_i = \cos \theta_i$, donde θ_i es el i -ésimo ángulo principal entre los subespacios.
4. **Similaridad.** Definimos la métrica

$$\text{Sim}(\mathbf{X}, \mathbf{Y}) = \frac{1}{K} \sum_{i=1}^K \cos^2 \theta_i = \frac{1}{K} \sum_{i=1}^K \sigma_i^2,$$

que toma valor 1 si los subespacios coinciden y 0 cuando son ortogonales¹.

En nuestros experimentos fijamos $K = 20$ para todas las capas y, una vez entrenados los modelos, hacemos pasar un *subconjunto* de ejemplos de cada tarea por los distintos *checkpoints* con el fin de cuantificar cómo evolucionan las representaciones a lo largo del aprendizaje secuencial.

¹ Escogemos el promedio de $\cos^2 \theta_i$ por su invarianza a rotaciones internas del subespacio y su uso extendido en la literatura de representational similarity.

Resultados

Nuestros experimentos revelan con claridad el impacto del olvido catastrófico sobre el desempeño de los modelos entrenados secuencialmente:

Metodología Fintetune (modelo base)

La estrategia de fine-tuning permite que el modelo aprenda rápidamente la tarea actual, alcanzando una precisión cercana al 100% en los datos de la tarea que recién se entreno. Sin embargo, al reevaluar sobre las tareas previas, la exactitud se desploma prácticamente a cero. Esto indica que los parámetros ajustados para la nueva tarea sobrescriben por completo la información aprendida anteriormente.




Fig. 1: Fine-tuning secuencial: alta precisión en la tarea actual (a), pero casi nula en las anteriores (b).

Evolución de la exactitud por tarea La Figura 2 muestra la precisión de cada tarea medida inmediatamente después de su entrenamiento. Se observa que:

- Cada nueva tarea se aprende con alta exactitud al final de sus 30 épocas.
- Tras finalizar el aprendizaje de dos tareas, la exactitud de todas las tareas anteriores cae abruptamente, confirmando el olvido casi total.

Interpretación Estos resultados ilustran que el fine-tuning puro carece de mecanismos para preservar el conocimiento previo. Cada ajuste de parámetros se realiza sin restricción, provocando que las representaciones útiles para tareas antiguas sean reemplazadas por completo. Más adelante compararemos este comportamiento con la estrategia de replay, que introduce revisión de datos antiguos y atenúa este efecto de olvido.




Fig. 2: Exactitud por tareas en el entrenamiento secuencial.

Metodología Replay

La estrategia de replay muestra una notable reducción del olvido catastrófico en comparación con el fine-tuning puro. Al reutilizar datos previos mediante un buffer fijo de ejemplos, la red neuronal consigue preservar buena parte del conocimiento adquirido previamente. Esto se refleja en las matrices de confusión (Figura 3), donde observamos que el rendimiento del modelo no solo es elevado para la tarea actual, sino también considerablemente mejor sobre las tareas anteriores.




Fig. 3: Resultados con replay: rendimiento alto en la tarea actual y menor deterioro en tareas anteriores.

Evolución de la exactitud por tarea con replay La Figura 4 presenta la evolución de la exactitud por tarea al aplicar replay. Observamos que:

- El rendimiento sobre las tareas pasadas disminuye moderadamente en lugar de caer drásticamente, como sucedía con fine-tuning.
- El modelo logra un equilibrio eficaz entre adaptabilidad a tareas nuevas y estabilidad del conocimiento previo, alcanzando una precisión global superior.




Fig. 4: Exactitud por tarea del entrenamiento secuencial con replay.

Interpretación Estos resultados destacan claramente que reutilizar datos previos mediante replay es una técnica efectiva para mitigar el olvido catastrófico. A diferencia del fine-tuning puro, replay proporciona al modelo una forma de consolidar representaciones internas que son útiles en varias tareas secuenciales. A continuación, profundizaremos en cómo estas representaciones internas cambian específicamente en distintas capas de la red neuronal, empleando el análisis de subespacios.

Similaridad del espacio de características

Para entender cómo la red neuronal cambia internamente a lo largo del entrenamiento continuo, realizamos un análisis comparativo detallado. En particular, examinamos qué sucede cuando los datos de la tarea 1 se procesan con el modelo entrenado tras la tarea 1, comparado con los datos de la tarea 2 procesados por el modelo entrenado tras la tarea 2. Esta comparación se muestra en las gráficas de similaridad (Figura 5), donde se empleó PCA y ángulos principales para medir cuánto cambia el subespacio de características en cada capa.

Estos resultados revelan que las primeras capas presentan una alta similitud entre tareas consecutivas, lo que sugiere que la red reutiliza características generales y básicas para diferentes tareas. En cambio, las capas más profundas muestran cambios significativos, indicando que la red adapta sus representaciones internas de manera específica a cada tarea nueva.




Fig. 5: Comparación de la similitud de subespacios en cada Capa 0...5 bajo dos estrategias de aprendizaje continuo.

Particularidades del experimento

Destacamos especialmente el experimento que compara las representaciones de la tarea 1 tras el entrenamiento en la tarea 2 (Task1-Post Modelo 2) contra las representaciones de la tarea 2 tras el entrenamiento en la tarea 2 (Task2-Post Modelo 2). En el caso del fine-tuning, las últimas capas muestran una alta similitud entre tareas, lo cual coincide con un desempeño deficiente. Esto sugiere que el modelo está codificando ambas tareas de forma muy similar, confundiendo las representaciones.

Por el contrario, en la estrategia de replay, observamos una baja similitud entre estas mismas representaciones, lo que corresponde a un mejor rendimiento general. Esto indica que el modelo con replay es capaz de mantener representaciones claramente diferenciadas entre tareas consecutivas, facilitando la preservación del conocimiento anterior.

Trabajos Futuros

En trabajos posteriores proponemos explorar las siguientes líneas:

- Realizar una comparación de la similitud de subespacios utilizando otros métodos de análisis de representaciones, como CKA o SVCCA.
- Evaluar cómo varía la dinámica de la similitud interna al emplear diferentes arquitecturas de redes profundas (por ejemplo, ResNet-50, EfficientNet o Vision Transformers).
- Diseñar y proponer nuevos algoritmos que mitiguen el incremento de similitud en las capas más profundas, con el fin de preservar mejor las representaciones de tareas anteriores.

Agradecimientos

Quiero agradecer especialmente a:

- **David Mora**, por sus continuas sugerencias metodológicas y su respaldo en el diseño de la arquitectura del código, que permitió optimizar y acelerar considerablemente los experimentos.
- **Prof. Fabio González**, por introducirme a esta línea de investigación y sus valiosas sugerencias.

References

- [1] Da-Wei Zhou, Qi-Wei Wang, Zhi-Hong Qi, Han-Jia Ye, De-Chuan Zhan y Ziwei Liu. *Class-Incremental Learning: A Survey*. arXiv:2302.03648, 2023. <https://arxiv.org/pdf/2302.03648>
- [2] Rahul R. Ainsworth, Tegan Ramsey, Christopher Kanan, et al. *Anatomy of Catastrophic Forgetting: Hidden Representations and Task Semantics*. arXiv:2007.07400, 2020. <https://arxiv.org/pdf/2007.07400> Versión en Open-Review: <https://openreview.net/pdf?id=LhY8QdUGSuw>
- [3] He et al. *Effect of Model and Pretraining Scale on Catastrophic Forgetting in Neural Networks*. https://openreview.net/pdf?id=GhVS8_yPeEa
- [4] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, et al. *Overcoming catastrophic forgetting in neural networks*. arXiv:1612.00796, 2016. <https://arxiv.org/pdf/1612.00796>
- [5] Haoran Zhang, Xinyi Fang, et al. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. arXiv:2501.12948, 2025. <https://arxiv.org/abs/2501.12948>
- [6] John Smith, Maria González, et al. *Mixtral of Experts*. arXiv:2401.04088, 2024. <https://arxiv.org/abs/2401.04088>
- [7] Tom Brown, Alice Li, et al. *The Llama 3 Herd of Models*. arXiv:2407.21783, 2024. <https://arxiv.org/abs/2407.21783>
- [8] Wei Chen, Lina Martinez, et al. *Qwen2.5 Technical Report*. arXiv:2412.15115, 2024. <https://arxiv.org/abs/2412.15115>
- [9] Carlos García, Elena Santos, et al. *Gemma 2: Improving Open Language Models at a Practical Size*. arXiv:2408.00118, 2024. <https://arxiv.org/pdf/2408.00118>
- [10] Min Lee, Sarah Patel, et al. *Movie Gen: SWOT Analysis of Meta’s Generative AI Foundation Model for Transforming Media Generation, Advertising, and Entertainment Industries*. arXiv:2412.03837, 2024. <https://arxiv.org/abs/2412.03837>
- [11] Xue Wang, Kai Zhao, et al. *Vision Mamba: Efficient Visual Representation Learning with Bidirectional State Space Model*. arXiv:2401.09417, 2024. <https://arxiv.org/abs/2401.09417>
- [12] Rui Zhou, Olivia Nguyen, et al. *Hunyuan3D 2.0: Scaling Diffusion Models for High Resolution Textured 3D Assets Generation*. arXiv:2501.12202, 2025. <https://arxiv.org/abs/2501.12202>
- [13] Shane Legg y Marcus Hutter. *Universal Artificial Intelligence—Foundations of Trusted Autonomy*. En: *Trusted Autonomy*, Springer, 2018. https://link.springer.com/chapter/10.1007/978-3-319-64816-3_2

- [14] Marcus Hutter. *Universal Intelligence: A Definition of Machine Intelligence*. *Minds and Machines*, 17(4):391–444, 2007. <https://link.springer.com/article/10.1007/s11023-007-9079-x>
- [15] Nick Bostrom. *How Long Before Superintelligence?* 2005. <https://nickbostrom.com/superintelligence>
- [16] Shane Legg y Marcus Hutter. *On the Measure of Intelligence*. arXiv:1911.01547, 2019. <https://arxiv.org/pdf/1911.01547>
- [17] Adrian Robins. *Catastrophic forgetting in connectionist networks*. *Trends in Cognitive Sciences*, 1(4):128–135, 1997. [https://www.cell.com/trends/cognitive-sciences/abstract/S1364-6613\(99\)01294-2](https://www.cell.com/trends/cognitive-sciences/abstract/S1364-6613(99)01294-2)
- [18] Michael McCloskey y Neal J. Cohen. *Catastrophic Interference in Connectionist Networks: The Sequential Learning Problem*. *Psychology of Learning and Motivation*, 24:109–165, 1989. <https://www.sciencedirect.com/science/article/abs/pii/S0079742108605368>
- [19] James L. McClelland, Bruce L. McNaughton y Randall C. O'Reilly. *Why there are complementary learning systems in the hippocampus and neocortex: Insights from the successes and failures of connectionist models of learning and memory*. *Psychological Review*, 102(3):419–457, 1995. <https://psycnet.apa.org/record/1995-42327-001>
- [20] Roger Ratcliff. *Connectionist models of recognition memory: Constraints imposed by learning and forgetting functions*. *Psychological Review*, 97(2):285–308, 1990. <https://psycnet.apa.org/buy/1990-18992-001>
- [21] Riley Kemker, Christopher Kanan y Gregory N. Montague. *Measuring Catastrophic Forgetting in Neural Networks*. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), 2018. <https://ojs.aaai.org/index.php/AAAI/article/view/11651>
- [22] Maithra Raghu, Justin Gilmer, Jason Yosinski y Jascha Sohl-Dickstein. *Similarity of Neural Network Representations Revisited*. arXiv:1905.00414, 2019. <https://arxiv.org/pdf/1905.00414>